

ASK-DAO-MACHINE • 知识发现系统

ask-dao 知识发现系统 在生物医学领域的实践

道

已有的 AI4S 生态擅长**解决问题**——给定问题，它能算出答案。但「**问题从哪来**」这一环长期空缺：能定义问题、提出问题的系统，远比能解题的系统稀缺。

ask-dao 通过**问题路**和**想象路**两种方式来产生新问题与新知识。

道生一，一生二，二生三，三生万物 • 不是问答机，也不是单纯的问题制造机 —— 它是一台知识发现机器

一句话概括这次汇报

机器能**稳定产出真问题**了；新的知识也第一次被**算出来了**；但**世界新问题（N3）至今仍是 0**——这一点我不粉饰。

一、原理

两条独立的路（问题路 / 想象路）+ 四道门 + 四个等级（N0–N3）。**判不了的不产出**，两条路互不评判。

二、在生物医学的实践

一篇真实开放获取论文（CC BY 4.0）→ **54 条**可判问题；其中 **3 条**是机器从论文自报的 HR/CI **直接算出来的**残余混杂门槛。

三、dao 模型在生物医学的实践

一个专门用来提问的微调模型：v0.3 = v0.2 + RFT 后训练，从论文里提出作者没明说的开放科学问题。目前限制于生物医学领域。

四、扩展的实践

同一套判据换领域：**27 个领域 / 702 个配对 / 144 座结构桥梁**；想象路走完 **6,642** 个组合词；音乐与记录域重算出的已知结果**对上了**。

五、方向与瓶颈

方向：**多模态实体提取**（图像 / 声音 → 直接抽实体，尚未实现）。瓶颈：**尚未发现 N3 级新问题**。

一、原理 01

两条独立的路，两套成功标准

这是 v0.3.0 确立的架构，此后没有变过：**判不了的不产出**，两条路互不评判。



问道系统架构：两条相互独立的路 + 四模块 + 判定层 + 经验检索桥。图内每个数字、模块名与状态词都对应仓库实现或 `out/demo/*.json` 的真实记录。

实现：`src/ask_dao_machine/` · 架构图见项目站点 §系统结构。

问题路 · 成功标准

答案成立 / 可判。每条问题必须带 `route`（判定方式），判不了的不产出。

想象路 · 成功标准

语法正确 + 逻辑通畅 + 有推理判断——不是「有真实所指」。

互不评判

用问题路的逻辑（「这新吗」「有真实所指吗」）去判想象路的概念，是**范畴错误**。

经验检索桥（可选）

把组词词接到现实经验（维基双通道 + arXiv 回退 → 经验锚点）。**过桥不改变任何判定**，检索失败即退化为无脚手架。

什么算「新」：四道门 + 四个等级

把「新」拆成**可操作的门**，而不是形容词。四道门全过才叫 N3——**至今 = 0**。



四道门（上）与四个等级（下）。纪律：**显著性 > 新颖性**——任选参数的序列同样「检索未见」，只有显著性证书拦得住。

N0 已知 → N1 大概率已知 → N2 疑似未见 → **N3 世界新**。「文中未见」只写在「参照系未见」一栏，不等于文献没有。

问题从哪来：四种机制

前三种通用，第四种是领域包。「作者已提出」与「机器提出」必须分开标注——前者不算新问题。

① 作者自陈未解

抓 open problem / remains unclear / 尚不明确。来源标注：**作者已提出（不算新）**。

② 文本张力

抓 however / yet / inconsistent 处的分歧。来源标注：**机器提出**。

③ 结构追问

对结论句套四问：**范围 / 反例 / 机制 / 定量**。来源标注：**机器提出**。

④ 领域包（生物医学）

10 类方法学缺口 + 从 HR/CI **直接算** E-value。来源标注：机器提出 / 作者已论及（**分标**）。

实现：src/ask_dao_machine/paper.py · domains_biomed.py；产物每条带 evidence（触发它的原文句）与 route（判定方式）。

常吃代糖，会不会更容易得肾病？

论文：*Association of artificial sweeteners intake and risk of CKD: a prospective cohort study*（人工甜味剂摄入与慢性肾病风险的关联 · 前瞻性队列研究）。开放获取，CC BY 4.0，全文 32,787 字符。

问的问题

常吃人工甜味剂（代糖：阿斯巴甜、三氯蔗糖这类）的人，会不会更容易得**慢性肾病（CKD）**？

怎么做的

英国生物样本库 **156,000 人**，跟踪中位 **13.3 年**；用一次 24 小时饮食回想记录吃了什么，再看谁后来确诊肾病。

三个发现

① 代糖吃得最多的那组 vs 完全不吃：风险高 **19%**（HR 1.19）。② 代糖多 **且** 遗传风险高：风险高 **49%**（HR 1.49）。③ 把糖换成等甜度的代糖：风险高 **2%**（HR 1.02）。


作者结论

代糖与肾病风险升高有关，且这个关联在各遗传风险层都存在；**换代糖并不能降低风险**。

关键前提：这是**观察性研究**，不是随机试验——研究者没法随机分配谁吃代糖。这一点决定了下一页要讲的问题，也是机器能插上手的地方。

一篇论文 → 54 条可判问题

输入：CC BY 4.0 开放获取临床研究（PMC13331974，UK Biobank n=156,000，中位随访 13.3 年，32,787 字符）。作者自陈未解命中 0 条——所以这 54 条都是机器提出的。



上：54 条的来源构成。下：29 条方法学追问里，主题**作者已在文中论及 23 条，文中未见 6 条**。

- ③ 结构追问
16 条：对结论句套范围 / 反例 / 机制 / 定量四问。
- ② 文本张力
6 条：however / yet 处的分歧 → 形式化追问。
- ④ 方法学追问
29 条：10 类缺口，每条带原文句子 + 判定路由。
- 机器算出数值
3 条：从论文自报 HR/CI 算残余混杂门槛（下一页）。

```
命令：ask-dao-machine paper papers/biomed/PMC13331974.md --domain biomed --out out/biomed_demo
```

机器提出的问题，长什么样

下面是**产物里的原句，一字未改**。每条都指回触发它的原文句子，并给出判定方式（`route`）——**问题必须写成可判形式，否则不产出**。

— **【残余混杂强度】 判定路由：E-value / 敏感性分析（可精确计算）**

该效应是「已调整」之后剩下的：残余混杂要多强才能把它解释掉？把它写成可算的形式：给定效应量与置信区间，算 E-value（未测混杂与暴露、结局的关联强度各自要达到多少，才能把效应推到无效），并给出最小混杂强度数值。

— **【因果方向】 判定路由：滞后/剔除分析（lag analysis）+ 反向孟德尔随机化**

文中给出的是关联，但设计默认了 $X \rightarrow Y$ 的方向：反向因果（结局或早期病变改变了暴露）能否解释该效应？用可检验的形式说：把随访前 k 年发生的事件剔除（lag 分析），效应量随 k 如何变化？若 $k \geq 2$ 年就衰减到 1，说明什么？


— **【测量误差方向】 判定路由：回归校准 + 重复测量子样本**

暴露/结局是自报或单次测量的：这类误差是**非差异性**（把效应推向无效、低估）还是**差异性**（可能制造假阳性）？写成可判形式：用重复测量做回归校准，报告校准系数与校准后的效应量；若校准后效应变大，说明原结论被低估。

另外两类：**③结构追问**（对结论句套范围 / 反例 / 机制 / 定量四问）与**②文本张力**（however / yet 处的分歧）。全部 54 条的原句见 `docs/guide/demo-biomed.md`。

三个结论，强弱其实差很多

观察性研究有个**天生软肋**：**没人测过的东西**（残余混杂）可能才是真凶——比如「本来肾就不好的人更爱喝零度可乐」。E-value 把「可能存在残余混杂」这句含糊话**变成一个数**：**那个东西得多强，才能把这条结论解释掉？**



条形越长 = 越难推翻 = 结论越稳；原点 1 表示「隐藏因素毫无作用」。黑色短竖线是按 95% CI 下界重算的保守读数（更低 = 更脆弱）。


- 论文自己怎么处理
只说一句「可能存在残余混杂」就过去了。原文中 “E-value” 出现 0 次——这三个数是机器算的。
- ① 代糖 vs 不吃
门槛 1.67：要有中等强度的隐藏因素才能推翻。不算铁证，但站得住。
- ② 代糖多 + 遗传高风险
门槛 2.34：现实里很少有这么强的因素。这是三条里最稳的。
- ③ 用代糖替代糖
门槛只有 1.16：微弱偏差就能推翻。论文说「换代糖没有好处」，但这个数据撑不起这句话。

纪律：这是**门槛，不是结论**。1.67 不等于「代糖真的有害」，也推不出任何饮食、用药或诊断建议；任何人都能用论文里的数字复核这三个数。

二、在生物医学的实践 • 真实使用

真实跑一遍： 命令与产物

下面是**真实命令序列与未删改的输出**（不是示意）。产物固定落在 `--out` 目录：`problems_*.json` + `REPORT.md`。



① 取论文： `data fetch` 从 Europe PMC 拉开放
获取全文



② 跑批： `paper ... --domain biomed`



③ 逐条问题：带原文证据句 + 判定路由



④ 汇总： `REPORT.md` 一页人话

完整回放与逐条证据句见手册：`docs/guide/demo-biomed.md`。

这次实践学到的三件事

经验比结果更值得带走——下面三条都是被真实数据打出来的，不是设计时想到的。

— ① 必须把「作者已提出」单独分出来

29 条方法学追问里 **23 条的主题作者已在文中论及**。机器加的是**可判形式**（滞后分析、E-value 门槛、RERI、回归校准...），不是话题本身。不分标就会把「复述」当成「发现」。

— ② 领域包的价值在于「会算」

10 类缺口只是清单；真正有用的是**从论文自报的 HR/CI 直接算出门槛**——这是任何读者都能复核的数，而不是一句「可能有残余混杂」。


— ③ 门槛 ≠ 结论

E-value 1.67 说的是「混杂要强到这个程度才能解释掉」，**不是说效应是真的**，更推不出任何用药、摄入或诊断建议。这条边界必须写在产出里，而不是写在附录里。

三、dao 模型在生物医学的实践

dao-v 0.3：一个专门用来提问的微调模型

v0.3 = v0.2 + RFT 后训练（low-lr 训练 + LLM-as-judge 过滤数据）。它的任务不是回答问题，而是**从论文证据、方法局限与结果细节中，提出作者没有明说、但值得进一步探究的开放科学问题**。目前领域限制于生物医学。



ModelScope studio 上的**真实运行界面**（Ask-Dao v0.3 · 生物医学知识发现机器）：左侧是论文的摘要 / 讨论 / 结论，右侧是模型现场生成的候选问题，底部可调候选数量与 temperature。

地址：modelscope.cn/studios/skopskp/dao-v-0.3。当前跑在免费 CPU 模式（每次生成约 30–90 秒），所以界面上把候选数调小。

模型现场生成的三个问题（原句）

同一个输入（就是上一篇论文的摘要 / 讨论 / 结论），模型给出的候选问题——**注意它们都是问句，而且是原文没问过的。**

— 候选 1 • 剂量差异

在不同剂量水平上，糖精（saccharin）、阿斯巴甜（aspartame）和安赛蜜（acesulfame K）对 CKD 风险的影响是否存在差异？

— 候选 2 • 时间滞后

在该研究中，通过 24 小时膳食回顾评估人工甜味剂摄入量时是否存在时间滞后效应？

— 候选 3 • 追问反直觉处

为什么在高糖摄入水平上用人工甜味剂代替蔗糖并未降低肾病风险？

Holdout 对比：候选均值 reward **0.7113** vs v0.2 的 0.6888，配对头对 **3:2:7** 领先。换句话说，微调之后模型提出的问题，被判为「值得探究」的比例更高了。

这个模型做到了什么、还差什么

它已经能**稳定产出真问题**；但它的能力边界必须说清楚。

— 做到了：会问「反直觉处」

候选 3 是模型自己发现论文里的反直觉点——论文说「换代糖没有好处」，模型直接追问**为什么没有降低风险**。这不是复述，是找到了值得深挖的缝。

— 做到了：问题带领域手艺

候选 1 问不同甜味剂**种类**的差异，候选 2 问 24 小时膳食回顾的**时间滞后**——这两条都是流行病学方法学里的真问题，不是泛泛而谈。

— 边界一：只有生物医学

目前**领域限制于生物医学**，靠的是领域语料与后训练；换领域需要重新做数据与训练。

— 边界二：它只提问，不判定

模型负责「问得好」，**判定交给判定器与人类**——它产出的候选仍需过四道门，不能自称发现。

分工：**模型提问题** → **判定层筛真假** → **人类裁决要不要投入**。这也是为什么 N3 仍为 0：会提问不等于发现了世界新知识。

另一条路：把「造词」做成能跑完的流水线


想象路不是问题路的子功能，而是与它**并列的一条路**。6,642 个领域专业词组合，每个都要走完五步，产出的是**被理解的概念**。



五步流水线。原则：**每个词都有意义，只不过是我们缺少想象力，无法理解它**——因此不存在空想。

问题路：544 条问题覆盖 23 个领域

这一代把「提问题」从零散试探变成**全领域并行扫描** + **分层问题树**，并第一次有了独立的裁决环节。




544 条问题的领域分布（条数最多的前 14 个领域）。朱砂标出的是与生物 / 医学相关的领域。

- **全领域扫描**
领域引擎并行产出，每个领域一份问题清单。
- **反例驱动**
专门提「机器结算不了」的问题——**只提自己答不出的。**
- **问题树**
L0-L5 分层 + 谱系门：每爬一层必须机器实测。
- **入口多样**
外部信息（网页 / arXiv / 科学史）· 日常疑问 · 母题，都能成为问题的种子。

产物： `out/demo/discovery_manifest.json` （544 条，字段含 `daily_question` → `scientific_question` → `judge_route`）。

独立裁决：15 个进制命题的判决

这是全项目里最像「新知识」的一类产出，判据是数值汇合，不是证明。换一套实现重算，结果必须一致。



青 confirmed 13 (例外集在 N1 档不再新增) · 青铜 open 1 (例外仍在冒) · 朱砂 rejected 1 (出现新例外) ——机器自己否掉了自己的命题。

- 命题
每个 $n \geq 4$ 可写为 base-b 回文数 + 素数; $b \geq 4$ 时例外集有限且很小。
- 判据
 $N0 = 5 \times 10^6 \rightarrow N1 = 10^7$, 两档的例外集是否汇合、有没有冒出新例外。
- 边界推进
base 10 推到 **10⁸ 零例外** (人类讨论此前止于 $\sim 10^6$) , 两种独立实现交叉验证。
- 自我更正
旧账本曾记 base 4 有 20 万个例外, 真值 **5**——**错的是账本, 不是结论**, 并出更正页。

分级: N0 已知 $\rightarrow$ N1 大概率已知 $\rightarrow$ N2 疑似未见 $\rightarrow$ N3 世界新。 **N3 至今仍为 0。**

系统侧学到的两件事

这两条都是「机器自己试出来」的，而不是从外部抄来的方法论。

— ① 独立实现比自证更有用


同一命题换一套实现重算（另写 FFT 版本复算 base 3–47），**b=3 的 68 个例外清单逐项一致**才敢认。自证只能发现笔误，换实现能发现口径错。

— ② 账本必须可作废

旧账本记 base 4 有 20 万个例外，真值是 5。**记错账比算错数更危险**——所以有了 `docs/novelty_ledger_corrections.md`，对 1,219 处标注 + 三套独立复算 + 作废声明。

领域融合：27 个领域 → 144 座结构桥梁

融合不是把两个领域的词拼在一起，而是找**共享结构**；没有共享结构的配对判为**空洞笛卡尔积**，不计入桥梁。



27 个领域两两配对得 702 个组合，其中 144 个被判定为共享结构 → 144 个跨域候选（全部可算）。

- 为什么不是排列组合
两个领域没共享结构时，拼出来的问题是**套话**，不是问题。
- 生物相关的融合
跨域候选里有**牵涉生物学的桥梁**（如「用数论方法问生物对象」），这类候选直接落到可算的判定路由上。
- 每条都实跑过
144 条候选**全部标注为「可算」**，各带一条判定路由。

产物： `out/demo/field_fusion.json` (fields / total_pairs / cross_hot / candidates) 。

同一套判据，换领域照样跑

复核性结果的价值是**校准自己**：机器重算出的已知结果对上了，才有资格谈没见过的那部分。

音集集合类 Tn/TnI
机器重算 224
与 Forte 224 一致（对表通过）

多完全数 k=2,3,4
{6,28,496,8128} / {120,672,523776} / {30240,32760}
与 OEIS A007539 对表通过

基 10 回文+素数覆盖
推到 10⁸ 零例外
两种独立实现交叉验证通过

未见候选（分级）
独立 5 · 强 34 · 短 2
OEIS 沉默代理 + 机制非平凡（非文献门）

未见候选的领域族：回文+素数覆盖(跨进制) 14 · 质数+多边形覆盖 7 · Collatz链长 1 · 音集音程向量 5 · D4纹样轨道数 7


三项与已知文献/数据库对表通过（音乐集合类 224 与 Forte 一致；多完全数与 OEIS A007539 一致；base 10 覆盖两种实现交叉验证）。

- 数学 · 序列结构
Collatz 链长、多边形数覆盖、5×5 二值纹样 D4 轨道数——可迭代枚举复算。
- 音乐 · 集合类
Tn/TnI 集合类 **224**（与 Forte 224 一致）；最大熵集合类**恰 2 个**。
- 记录 · 多完全数
k=2,3,4: {6,28,496,8128} / {120,672,523776} / {30240,32760}（对齐 A007539）。
- 未见候选分级
独立 5 · 强 34 · 弱 0 · 短 2——**这只是 OEIS 沉默 + 机制非平凡，不是文献门，更不是显著性证书。**

诚实标注：分级不等于新颖性；它只说明「在参照系里没见到」，需要人工或文献门复核。

经验检索桥：6,642 个组合词接上现实经验

桥的作用是让想象力**有据可依**，而不是当裁判。检索未见**不等于**概念为假；见不到也不阻止理解。




6,642 个组合词过双通道检索：词条通道命中 558 个，其中已建成独立条目仅 37 个；抓成语料 49 个词条，写出经验锚点 7 处。

- **命中率本身就是发现**
词条通道命中约 8.4%，已建成独立条目约 0.6%。「检索未见」是常态，不是发现。
- **桥不改变判定**
过桥不改变任何判定；检索失败即退化为无锚点，概念照样成立（判据是「被理解」）。
- **默认不过桥**
默认只对少数指定组合写锚点；全量检索需要显式开关。

多模态实体提取：让图像与声音进入两条路

现在经验**只能以文字进入**系统；图像与声音还没有进入两条路的入口。下一步是把这个「反向」补上——**尚未实现**。



实线 = 现在能做的（文字 → 问题 / 概念）。虚线 = 目标（图像 / 声音 → 直接抽实体 → 两条路的入口）。**虚线框内是目标，不是成果。**

已有最小闭环：perceive 能把图像 → 结构特征 → 带判定路由的问题；但它抽取的是**结构特征**，还不是实体。

尚未发现 N3 级新问题

问题是真的、量也很大；但「真的」不等于「新的」。这台机器停在这一步。

各行单位不同，因此不做同轴对比；「真的」和「新的」必须分开量。		
产出问题（模型侧·问题路）	544	条，覆盖 23 个领域
产出问题（问道·一篇论文）	54	条，全部带判定方式
其中主题作者已在文中论及	23	条 / 29 条方法学追问
机器能独立裁决（且被复核）	13	个进制命题 / 共 15 个（rejected 1）
世界新问题（N3）	0	条

「文中未见」只说明索引里没有；OEIS 沉默也不是文献门——显著性证书才是唯一拦得住人的门。

「N3 = 0」在账本里被独立记下 11 次，从未改变。各行的单位不同，因此不做同轴对比。

差距的具体位置：机器能判的问题里，多数主题**前人已经问过**；真正缺的不是产能，而是**能穿过显著性证书、且前人没问过**的那一格。下一步要把力气放在「显著性证书」这道门上，而不是继续加产能。

ASK-DAO-MACHINE

谢谢

问道 · ask-dao-machine · MIT License · 全部数字可用仓库里的命令复现

项目站点 <https://shikunpneg.github.io/ask-dao-machine/>

命令行文档 <https://shikunpneg.github.io/ask-dao-machine/guide/cli.html>

生物学完整演示 <https://shikunpneg.github.io/ask-dao-machine/guide/demo-biomed.html>

结果与证据手册 <https://shikunpneg.github.io/ask-dao-machine/guide/results.html>

ModelScope • dao-v-0.3 <https://www.modelscope.cn/studios/skopskp/dao-v-0.3>

GitHub <https://github.com/shikunpneg/ask-dao>

道生一，一生二，二生三，三生万物